

CESAR School — RNA e Deep Learning

Especialização em Engenharia e Análise de Dados — Turma 2025.2

Atividade Aula 4.3 — TensorFlow Playground (Dataset Spiral)

Docente: Vitor Casadei | Discente: Caio Augustus Lima de Abreu Monteiro (calam@cesar.school)

Objetivo

Acessar o TensorFlow Playground (playground.tensorflow.org) e, utilizando apenas as duas entradas X_1 e X_2 , ajustar os parâmetros da rede (número de camadas, número de neurônios, função de ativação, taxa de aprendizado e fator de regularização) de modo a resolver o dataset **Spiral**, alcançando um *Test Loss* inferior a 0,1.

Solução obtida

A configuração final que resolveu o problema, com **Test loss de 0,093** (abaixo da meta de 0,1), está registrada na captura de tela abaixo.




Figura 1 — Solução do dataset Spiral no TensorFlow Playground. Arquitetura com 3 camadas ocultas (8, 8 e 4 neurônios), ativação Tanh, taxa de aprendizado 0,03, sem regularização, utilizando apenas X_1 e X_2 como entradas. Test loss = 0,093.

Configuração final

Parâmetro	Valor
Entradas utilizadas	X_1 e X_2 (apenas)
Número de camadas ocultas	3
Neurônios por camada	8, 8 e 4
Função de ativação	Tanh

Taxa de aprendizado (learning rate)	0,03
Regularização	Nenhuma
Test loss alcançado	0,093 (meta: < 0,1)

O que aprendi com o exercício

O dataset Spiral é o mais desafiador entre os disponíveis no Playground, por ser fortemente não linear: os pontos das duas classes se entrelaçam em braços espiralados que não podem ser separados por uma reta nem por fronteiras simples. Resolvê-lo utilizando apenas as entradas brutas X_1 e X_2 (sem recorrer a atributos derivados como X_1^2 , X_2^2 ou $\sin(X)$) exige que a própria rede construa internamente as transformações não lineares necessárias. A seguir, registro o impacto observado de cada parâmetro ao longo dos experimentos.

Número de camadas. A profundidade da rede mostrou-se determinante. Com apenas uma ou duas camadas, a rede tinha dificuldade em modelar a curvatura dos braços da espiral, estagnando em valores de perda elevados. A adição de uma terceira camada oculta forneceu a capacidade de composição necessária: cada camada combina e transforma as representações da anterior, permitindo que a fronteira de decisão se curve o suficiente para acompanhar a espiral, inclusive em sua região central, onde os braços se aproximam.

Número de neurônios por camada. A largura de cada camada define quantas transformações distintas a rede pode aprender em paralelo. Camadas com poucos neurônios (por exemplo, dois na primeira camada) atuaram como gargalo, limitando drasticamente a capacidade do modelo e impedindo a convergência. Ao ampliar as camadas para oito neurônios, a rede passou a dispor de representações intermediárias suficientes para descrever a geometria complexa dos dados. A última camada oculta, com menos neurônios (quatro), atua como uma etapa de combinação final dessas representações.

Função de ativação. A escolha da ativação influencia diretamente o tipo de fronteira que a rede consegue produzir. A função **Tanh**, por ser suave e contínua, gerou fronteiras de decisão arredondadas, que se ajustam naturalmente à forma curva da espiral. Foi a ativação que apresentou melhor desempenho neste problema. Funções lineares, em contraste, seriam incapazes de resolver o Spiral, pois reduziriam toda a rede a uma única transformação linear, qualquer que fosse o número de camadas.

Taxa de aprendizado (learning rate). Esse parâmetro controla o tamanho do passo na atualização dos pesos. Um valor intermediário (0,03) ofereceu um bom equilíbrio: rápido o suficiente para convergir em um número razoável de épocas, porém estável o bastante para não oscilar. Observou-se que taxas muito altas tornam o treinamento instável, com a perda oscilando sem convergir, enquanto taxas muito baixas tornam a convergência excessivamente lenta. Em particular, no Spiral, o ajuste fino do centro da espiral é a parte mais lenta, exigindo paciência (centenas a milhares de épocas) ou, alternativamente, a redução da taxa de aprendizado na fase final do treinamento.

Fator de regularização. A regularização penaliza pesos elevados, combatendo o sobreajuste ao custo de reduzir a capacidade efetiva do modelo. Neste exercício, como o objetivo era atingir uma perda muito baixa em um problema que exige alta capacidade de representação, a melhor estratégia foi manter a regularização desativada. Um fator de regularização elevado simplificaria demais a fronteira de decisão e impediria o modelo de capturar os detalhes finos da espiral. A regularização é mais útil quando há ruído nos dados ou sinais de sobreajuste — situação que não se configurou aqui, dado que as perdas de treino e de teste permaneceram próximas e baixas.

Conclusão. O experimento evidenciou que a resolução de um problema não linear como o Spiral depende da combinação equilibrada de todos os parâmetros: capacidade suficiente (profundidade e largura adequadas), uma função de ativação não linear apropriada (Tanh), uma taxa de aprendizado bem calibrada e a ausência de regularização excessiva. A solução final — três camadas (8, 8 e 4 neurônios), ativação Tanh, taxa de aprendizado 0,03 e sem regularização — atingiu um Test loss de 0,093, cumprindo o objetivo proposto.